INFORME ANÁLISIS DE LAS VOTACIONES KNN IN NEO4J

Nombre: Jordan Murillo

Fecha: Viernes, 22 de mayo de 2020

Tema: kNN Classification of members of congress using similarity algorithms in Neo4j.

Requerimientos:

- Neo4i
- Neo4j graph algorithms plugin
- Neo4j APOC plugin

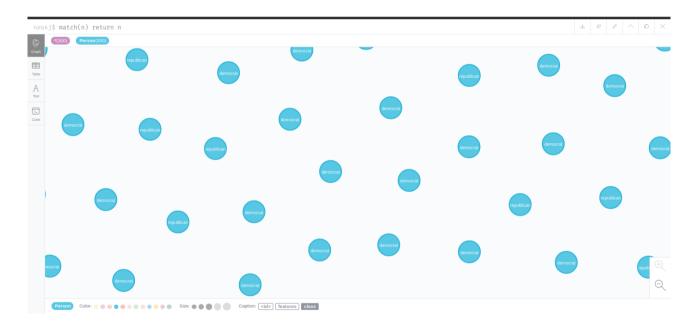
Base de Datos – Dataset

Tomaremos el archivo csv de un link de internet:

Código Neo4j

```
LOAD CSV FROM "http://archive.ics.uci.edu/ml/machine-learning-databases/voting-
records/house-votes-84.data" as row
CREATE (p:Person)
SET p.class = row[0],
    p.features = row[1..];
```

Resultado



Votos Perdidos

Ver votos perdidos

MATCH (n:Person)

```
WHERE "?" in n.features RETURN count(n)
```

Resultado



Visualizar distribución de votos perdidos por miembro

MATCH (p:Person)

```
WHERE '?' in p.features
WITH p,apoc.coll.occurrences(p.features,'?') as missing
RETURN missing,count(*) as times ORDER BY missing ASC
```

Resultado



Eliminar votos perdidos mayores a 6 por cada miembro

MATCH (p:Person)

```
WITH p,apoc.coll.occurrences(p.features,'?') as missing WHERE missing > 6 DELETE p
```

Resultado



Entrenamiento y datos para pruebas

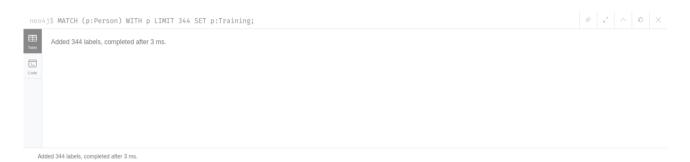
Seleccionar datos para entrenamiento que son 80% de los datos

80%=344

MATCH (p:Person)

WITH p LIMIT 344 SET p:Training;

Resultados

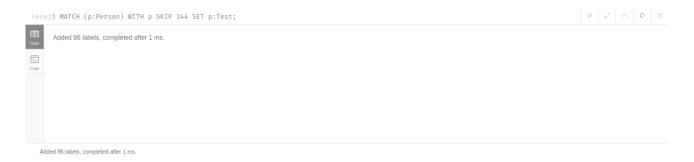


Seleccionar datos para pruebas que son el 20%

MATCH (p:Person)

WITH p SKIP 344 SET p:Test;

Resultados



Creación de vectores para el análisis de la similitud mediante la distancia euclidiana.

Tomar en cuenta que y=1, n=0 y ?=0.5

```
MATCH (n:Person)

UNWIND n.features as feature

WITH n,collect(CASE feature WHEN 'y' THEN 1

WHEN 'n' THEN 0

ELSE 0.5 END) as feature_vector

SET n.feature vector = feature vector
```

Resultado



kNN classifier algorithm

```
MATCH (test:Test)

WITH test,test.feature_vector as feature_vector

CALL apoc.cypher.run('MATCH (training:Training)

WITH training,gds.alpha.similarity.euclideanDistance($feature_vector, training.feature_vector) AS similarity
```

```
ORDER BY similarity ASC LIMIT 3

RETURN collect(training.class) as classes',

{feature_vector:feature_vector}) YIELD value

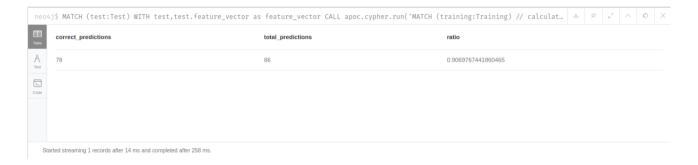
WITH test.class as class,

apoc.coll.sortMaps(apoc.coll.frequencies(value.classes), '^count')[-1].item as predicted_class

WITH sum(CASE when class = predicted_class THEN 1 ELSE 0 END) as correct_predictions, count(*) as total_predictions

RETURN correct_predictions, total_predictions, correct_predictions / toFloat(total predictions) as ratio
```

Resultado



Conclusión

En la práctica aprendimos como usar Neo4j para aplicar algoritmos que nos ayudar a interpretar datos y dar resultados como lo haría un sistema experto de casos (CBR). Con esto aprendemos también a utilizar herramientas nuevas para hacer de manera más rápido el análisis de los datos.

Webgrafia

- https://tbgraph.wordpress.com/2018/11/25/knn-classification-using-similarity-algorithms-in-neo4j/